

# Sztuczna Inteligencja

Soma Dutta

Wydział Matematyki i Informatyki, UWM w Olsztynie  
[soma.dutta@matman.uwm.edu.pl](mailto:soma.dutta@matman.uwm.edu.pl)

Wykład - 6: Zbiory przybliżone i Zbiory rozmyte

Semestr letni 2022

# Podsumowanie ostatniego wykładu

- ▶ Redukty i reguły generowane przy użyciu reduktów
- ▶ Skracanie reguł w taki sposób, aby zawierały minimalną liczbę deskryptorów
- ▶ Klasyfikacja nowego przypadku za pomocą reguł

# Plany

- ▶ Klasyfikacja zbioru przykładów testowych nie jest tak prosta - czasami trzeba wykonać operację aproksymacji
- ▶ Nauczymy się przybliżonych operacji bazujących na zbiorze przybliżonym
- ▶ Istnieje inne podejście do przybliżania zbioru obiektów, które nie mają jednoznacznego opisu. Jest to znane jako teoria zbiorów rozmytych.

# Przykład - 1: pierwsza metoda

	<i>a</i>	<i>b</i>	<i>c</i>	<i>d</i>	<i>dec</i>
<i>o</i> <sub>1</sub>	0	2	1	0	0
<i>o</i> <sub>2</sub>	1	2	2	1	0
<i>o</i> <sub>3</sub>	2	0	2	1	1
<i>o</i> <sub>4</sub>	0	2	1	1	2
<i>u</i>	0	0	2	1	?

► Reguły:

$$b = 2 \wedge c = 1 \wedge d = 0 \Rightarrow dec = 0$$

$$b = 2 \wedge c = 2 \wedge d = 1 \Rightarrow dec = 0$$

$$b = 0 \wedge c = 2 \wedge d = 1 \Rightarrow dec = 1$$

$$b = 2 \wedge c = 1 \wedge d = 1 \Rightarrow dec = 2$$

► Po skróceniu:

$$b = 2 \wedge d = 0 \Rightarrow dec = 0 \quad \text{lub} \quad c = 1 \wedge d = 0 \Rightarrow dec = 0$$

$$b = 2 \wedge c = 2 \Rightarrow dec = 0$$

$$b = 0 \Rightarrow dec = 1$$

$$c = 1 \wedge d = 1 \Rightarrow dec = 2$$

►  $Rules(u) = \{b = 0 \Rightarrow dec = 1\}$

► Zatem *u* jest klasyfikowany z *dec* = 1 z maksymalnym wsparciem 1.

## Przykład-2


- ▶ Zakładamy, że  $a_1$  = gorączka,  $a_2$  = kontakt z pacjentem,  $a_3$  = kaszel,  $d$  = Zainfekowany

	$a_1$	$a_2$	$a_3$	$d$
$o_1$	wysoka	bliski	średni	tak
$o_2$	wysoka	bliski	średni	tak
$o_3$	wysoka	bliski	średni	tak
$o_4$	więcej niż średnia	daleki	silny	nie pewne
$o_5$	więcej niż średnia	daleki	silny	nie
$o_6$	więcej niż średnia	daleki	lekki	nie
$o_7$	wysoka	bliski	średni	tak
$o_8$	więcej niż średnia	daleki	lekki	nie
$o_9$	więcej niż średnia	daleki	lekki	tak

- ▶  $\{\{o_1, o_2, o_3, o_7\}, \{o_4, o_5\}, \{o_6, o_8, o_9\}\}$
- ▶  $\{o_4, o_5\}, \{o_6, o_8, o_9\}$  mają sprzeczności, ponieważ mają elementy, które mają ten sam opis, ale różne decyzje


# Klasy równoważności w odniesieniu do atrybutów warunkowych

- ▶  $\{\{o_1, o_2, o_3, o_7\}, \{o_4, o_5\}, \{o_6, o_8, o_9\}\}$
- ▶ Jak znaleźć reguły opisujące  $\{o_4, o_5\}$  and  $\{o_6, o_8, o_9\}$  ?



# Klasy decyzyjne

- ▶ Klasy decyzyjne:
  - ▶ **Tak**:  $X_1 = \{o_1, o_2, o_3, o_7, o_9\}$
  - ▶ **Nie pewne**:  $X_2 = \{o_4\}$
  - ▶ **Nie**:  $X_3 = \{o_5, o_6, o_8\}$
- ▶ Jak opisać klasy decyzyjne  $X_1$ ,  $X_2$ ,  $X_3$ ?



# Jak możemy opisać klasy decyzyjne

	$a_1$	$a_2$	$a_3$	$d$
$o_1$	wysoka	bliski	średni	tak
$o_2$	wysoka	bliski	średni	tak
$o_3$	wysoka	bliski	średni	tak
$o_4$	więcej niż średnia	daleki	silny	nie pewne
$o_5$	więcej niż średnia	daleki	silny	nie
$o_6$	więcej niż średnia	daleki	lekki	nie
$o_7$	wysoka	bliski	średni	tak
$o_8$	więcej niż średnia	daleki	lekki	nie
$o_9$	więcej niż średnia	daleki	lekki	tak

- ▶ Klasa decyzyjna  $X_1 = \{o_1, o_2, o_3, o_7, o_9\}$
- ▶ Lower approximation (dolna aproksymacja):  $\underline{X}_{1A} = \cup\{[u]_A : [u]_A \subseteq X_1\} = \{o_1, o_2, o_3, o_7\}$  - Na podstawie informacji o elementach zawartej w wartościach atrybutów z A możemy stwierdzić, że elementy z pewnością należą do klasy decyzyjnej
- ▶ Upper approximation (górną aproksymacja):  $\overline{X}_{1A} = \cup\{[u]_A : [u]_A \cap X_1 \neq \emptyset\} = \{o_1, o_2, o_3, o_7, o_6, o_8, o_9\}$  - Na podstawie informacji o elementach zawartej w wartościach atrybutów z A możemy stwierdzić, że elementy być może należą do klasy decyzyjnej



# Opis klasy decyzyjnej

- ▶ Zauważmy, że za pomocą  $A$  nie możemy zdefiniować jednoznacznie  $X_1$ , ponieważ istnieją pewne wystąpienia w  $X_1$ , które mają różne właściwości.
- ▶ Opis  $X_1$  jest podzielony na trzy części: Pewne przypadki ( $\underline{X_{1A}}$ ), Możliwe przypadki ( $\overline{X_{1A}}$ ) i Graniczne przypadki ( $\overline{X_{1A}} \setminus \underline{X_{1A}}$ ).
- ▶ Możemy opisać klasę decyzji  $X_1$ , czyli 'Zainfekowany = Tak', w następujący sposób.
  - ▶ **Pewne przypadki** : gorączka = wysoka  $\wedge$  kontakt z pacjentem = bliski  $\wedge$  kaszel = silny  $\Rightarrow$  zainfekowany = tak.
  - ▶ **Możliwe przypadki**: gorączka = więcej niż średnia  $\wedge$  kontakt z pacjentem = daleki  $\wedge$  kaszel = lekki  $\Rightarrow$  zainfekowany = tak.

# Radzenie sobie ze sprzecznymi danymi

- ▶ Generalized decision function (uogólniona funkcja decyzyjna) :  
 $\partial_B(u) = \{dec(u') : u' \in [u]_B\}.$
- ▶ Na przykład,  $\partial_A(o_4) = \{\textit{nie pewne}, \textit{nie}\}$
- ▶ Rough membership function (funkcja przybliżonego należenia):  
 $\vec{\mu}_B(u) = \langle \mu_B^1(u), \mu_B^2(u), \dots, \mu_B^n(u) \rangle$  gdzie  $\mu_B^i(u) = \frac{|[u]_B \cap X_i|}{|[u]_B|}$  dla każdej wartości decyzji  $i$ .
- ▶ Na przykład,  $[o_6]_A = \{o_6, o_8, o_9\}$ . Więc  $\vec{\mu}_A(o_6) = \langle \frac{1}{3}, 0, \frac{2}{3} \rangle$ .
- ▶ Zakładając  $B = \{a_1, a_2\}$ , mamy tylko dwie klasy równoważności:  
 $\{\{o_1, o_2, o_3, o_7\}, \{o_4, o_5, o_6, o_8, o_9\}\}.$   
Więc,  $[o_6]_B = \{o_4, o_5, o_6, o_8, o_9\}$  i  $\vec{\mu}_B(o_6) = \langle \frac{1}{5}, \frac{1}{5}, \frac{3}{5} \rangle$ .
- ▶ Niech  $C = \{a_2, a_3\}$ . Należy notować, że  $C$  to redukt w poprzednim znaczeniu.
- ▶ Zauważmy, że  $[u]_A = [u]_C$  dla każdego elementu  $u \in \{o_1, \dots, o_9\}$ .
- ▶ Tak więc  $\partial_A(u) = \partial_C(u)$  oraz  $\vec{\mu}_A(u) = \vec{\mu}_C(u)$  dla każdego elementu  $u \in \{o_1, \dots, o_9\}$ .

# Niesprzeczna tabela decyzyjna


	$a_1$	$a_2$	$a_3$	$d$	$\partial_A$	$\vec{\mu}_A$
$o_1$	wysoka	bliski	średni	tak	$\{tak\}$	$\langle 1, 0, 0 \rangle$
$o_2$	wysoka	bliski	średni	tak	$\{tak\}$	$\langle 1, 0, 0 \rangle$
$o_3$	wysoka	bliski	średni	tak	$\{tak\}$	$\langle 1, 0, 0 \rangle$
$o_4$	więcej niż średnia	daleki	silny	nie pewne	$\{nie\ pewne, nie\}$	$\langle 0, \frac{1}{2}, \frac{1}{2} \rangle$
$o_5$	więcej niż średnia	daleki	silny	nie	$\{nie\ pewne, nie\}$	$\langle 0, \frac{1}{2}, \frac{1}{2} \rangle$
$o_6$	więcej niż średnia	daleki	lekki	nie	$\{tak, nie\}$	$\langle \frac{1}{3}, 0, \frac{2}{3} \rangle$
$o_7$	wysoka	bliski	średni	tak	$\{tak\}$	$\langle 1, 0, 0 \rangle$
$o_8$	więcej niż średnia	daleki	lekki	nie	$\{tak, nie\}$	$\langle \frac{1}{3}, 0, \frac{2}{3} \rangle$
$o_9$	więcej niż średnia	daleki	lekki	tak	$\{tak, nie\}$	$\langle \frac{1}{3}, 0, \frac{2}{3} \rangle$

- $(\text{gorączka} = \text{więcej niż średnia}) \wedge (\text{kontakt z pacjentem} = \text{daleki}) \wedge (\text{kaszel} = \text{silny}) \Rightarrow$   
 $Zainfekowany | \partial_A = \{nie\ pewne, nie\}$
- $(\text{gorączka} = \text{więcej niż średnia}) \wedge (\text{kontakt z pacjentem} = \text{daleki}) \wedge (\text{kaszel} = \text{silny}) \Rightarrow$   
 $Zainfekowany | \mu_A \langle 0, \frac{1}{2}, \frac{1}{2} \rangle$

# Przybliżenie przy użyciu metody zbiorów rozmytych


- ▶ To podejście różni się nieco od wcześniejszego. Podejście to uogólnia definicję zbioru w następujący sposób.
- ▶ Zbiór wszystkich parzystych liczb naturalnych:  $E = \{2, 4, 6, 8, \dots\} \subseteq \mathbb{N}$
- ▶ Funkcja charakterystyczna:  $Ch_E : \mathbb{N} \mapsto \{0, 1\}$  jest taka, że  $Ch_E(x) = 1$  jeśli  $x \in E$ , inaczej  $Ch_E(x) = 0$ .
- ▶ Jak zapisujemy zbiór wszystkich liczb rzeczywistych **bliskich 2**? To nie jest jednoznaczny opis i może mieć różne interpretacje.
- ▶ Możemy ten zbiór opisać za pomocą funkcji  $\mu_2 : \mathbb{R} \mapsto [0, 1]$  takiej że
$$\begin{aligned}\mu_2(x) &= 1, \text{ jeśli } 0 \leq |2 - x| \leq 1 \\ &= .9, \text{ jeśli } 1 < |2 - x| \leq 2 \\ &\vdots\end{aligned}$$
- ▶ Zamiast dwóch wartości logicznych (prawda i fałsz), dopuszcza się istnienie nieskonczenie wielu wartości (odpowiadających liczbom rzeczywistym od 0 do 1)

- ▶ Tak więc dla każdego  $x \in \mathbb{R}$ ,  $\mu_2(x)$  reprezentuje stopień przynależności  $x$  do pojęcia (bliskich 2) reprezentowanego przez  $\mu_2$ .
- ▶ Również można to zapisać następująco  $(x, \mu_2(x))$  dla każdego  $x \in \mathbb{R}$ .
- ▶ **Zbiór rozmyty**: Zbiór rozmyty z dziedziną  $X$  jest reprezentowany przez funkcję  $f : X \mapsto [0, 1]$ . Funkcję  $f$  nazywamy zbiorem rozmytym na dziedzinie  $X$ .




Pojęcia "ciepło" czy "gorąco" są określone w sposób nieostry: trudno jednoznacznie określić ich granice, ich zakresy mogą się częściowo pokrywać.



Funkcje mogą mieć kształt trapezu...



...trójkąta...



...ale też inny (np. sigmoidalny)...



...a zbiór  $X$  nie musi być zbiorem liczb rzeczywistych

# Reguły w rozmytych zbiorach

- ▶ We wcześniejszym podejściu zaczęliśmy od tabeli zawierającej przypadki i ich opisy pod względem wartości niektórych atrybutów
- ▶ gorączka = wysoka  $\wedge$  kontakt z pacjentem = bliski  $\wedge$  kaszel = sliny  $\Rightarrow$  zainfekowany = tak.
- ▶ W aktualnie rozważanym podejściu każde zdanie ma pewną wartość, które mogą być inne niż prawda lub fałsz, można je nazwać stopniem prawdy.
- ▶ Na przykład, reprezentujemy pojęcie wysoka jak o  $\mu_{wysoka} : [35, 42] \mapsto [0, 1]$  gdzie  $[35, 42]$  jest dziedziną dla temperatury gorączki. Może ta funkcja być taka, że
$$\begin{aligned}\mu_{wysoka}(x) &= 1 \text{ jeśli } x \geq 40 \\ &= .9 \text{ jeśli } 38 \leq x < 40 \\ &= .7 \text{ jeśli } 37 \leq x < 38 \\ &= .5 \text{ jeśli } 36 \leq x < 37 \\ &= .1 \text{ jeśli } 35 \leq x < 36\end{aligned}$$
- ▶ Gorączka może więc być traktowana jako zmienna, który może mieć wartości z  $[35, 42]$ . Jeśli gorączka ma wartość 38, stopień prawdziwości zdania 'gorączka = wysoka' jest  $\mu_{wysoka}(38) = .9$

# Obliczanie wartości prawdy w zdaniach prostych i złożonych

- ▶ 'gorączka = wysoka' jest przykładem prostego zdania.
- ▶ Zauważyliśmy, że każde proste zdanie jest reprezentowane przez zbiór rozmyty, czyli funkcja z odpowiedniej domeny do przedziału  $[0, 1]$ . Wartość prawdziwości zdania zależy od funkcji odpowiadającej temu rozmytemu zbiorowi.
- ▶ Np. zbiór rozmyty 'wysoka' jest reprezentowany przez funkcję  $\mu_{wysoka}$  z domeny temperatury do  $[0, 1]$ . Tutaj 'wysoka' dotyczy atrybutu 'gorączka', więc jako domenę mamy przedział temperatur.
- ▶ Podobnie 'silny' jest stosowany do atrybutu 'kaszel', więc możemy przyjąć domenę reprezentującą różną intensywność kaszlu, a pojęcie 'silny' można przedstawić jako zbiór rozmyty, czyli funkcja  $\mu_{silny}$ , która zwraca wartości w  $[0, 1]$ .
- ▶ Przypuszczamy
  - ▶ gorączka = wysoka ma stopień prawdziwości .9,
  - ▶ kaszel = silny ma stopień prawdziwości .7
- ▶ Jak obliczyć wartość prawdy zdania złożonego:  
(gorączka = wysoka)  $\wedge$  (kaszel = silny)



# Spójniki logiczne: klasyczny scenariusz z dwiema wartościami

Spójniki logiczne:  $\wedge$  (oraz),  $\vee$  (lub),  $\Rightarrow$  (jeśli ... to),  $\neg$  (nie)

- ▶ Niech  $p$  i  $q$  będą dwoma zdaniami.

$\wedge$	0	1
0	0	0
1	0	1

$\vee$	0	1
0	0	1
1	1	1

$\Rightarrow$	0	1
0	1	1
1	0	1

	$\neg$
0	1
1	0

- ▶  $\neg : \{0, 1\} \mapsto \{0, 1\}$ , i dla pozostałych spójników mamy  $\{0, 1\} \times \{0, 1\} \mapsto \{0, 1\}$ .
- ▶ Spójniki logiczne w kontekście zbiorów rozmytych są generalizowane z kontekstu dwuwartościowego

# Logika rozmyta: Koniunkcja

- ▶ Niech  $\alpha, \beta$  będą zbiorami rozmytymi na dziedzinie  $X$ . Tzn.,  $\mu_\alpha : X \mapsto [0, 1]$  i  $\mu_\beta : X \mapsto [0, 1]$
- ▶ Koniunkcję  $\alpha$  i  $\beta$  definiujemy jako zbiór rozmyty  $\alpha \wedge \beta$  o funkcji przynależności  $\mu_{\alpha \wedge \beta} : X \mapsto [0, 1]$  określony wzorem
$$\mu_{\alpha \wedge \beta}(x) = T(\mu_\alpha(x), \mu_\beta(x)) \quad \forall x \in X$$
- ▶ Funkcja  $T : [0, 1] \times [0, 1] \mapsto [0, 1]$  jest **T-normą**.

# Własności T-normy

- ▶ Warunki brzegowe:  
 $T(0, x) = 0$  oraz  $T(1, x) = x$ .
- ▶ Monotoniczność:  
Jeśli  $x \leq y$ ,  $T(x, z) \leq T(y, z)$ .
- ▶ Symetria:  
 $T(x, y) = T(y, x)$
- ▶ Łączność:  
 $T(x, T(y, z)) = T(T(x, y), z)$

# Przykładowe T-normy

- ▶ T-norma Zadeha:

$$T(x, y) = \min(x, y) \quad \forall x, y \in [0, 1]$$

- ▶ T-norma Mengara:

$$T(x, y) = x \cdot y \quad \forall x, y \in [0, 1]$$

- ▶ T-norma Łukasiewicza:

$$T(x, y) = \max(0, x + y - 1) \quad \forall x, y \in [0, 1]$$

# Przykład

Przymujemy  $X = \{x_1, x_2, x_3, x_4\}$

- ▶ Dla  $\alpha$  równego  $\{(x_1, 0.4), (x_2, 0), (x_3, 0.5), (x_4, 1)\}$  oraz  $\beta$  równego  $\{(x_1, 0.6), (x_2, 0.5), (x_3, 0), (x_4, 1)\}$  otrzymujemy następujące wyniki dla różnych koniunkcji :
- ▶ Zadeh:  $\alpha \wedge \beta$  równa się zbiorowi rozmytemu  $\{(x_1, 0.4), (x_2, 0), (x_3, 0), (x_4, 1)\}$
- ▶ Mengar:  $\alpha \wedge \beta$  równa się zbiorowi rozmytemu  $\{(x_1, 0.24), (x_2, 0), (x_3, 0), (x_4, 1)\}$
- ▶ Łukasiewicz:  $\alpha \wedge \beta$  równa się zbiorowi rozmytemu  $\{(x_1, 0), (x_2, 0), (x_3, 0), (x_4, 1)\}$

# Altarnetywa jako Ko-norma

- ▶ Warunki brzegowe:  
 $C(0, x) = x$  oraz  $C(1, x) = 1$ .
- ▶ Monotoniczność:  
Jeśli  $x \leq y$ ,  $C(x, z) \leq C(y, z)$ .
- ▶ Symetria:  
 $C(x, y) = C(y, x)$
- ▶ Łączność:  
 $C(x, C(y, z)) = C(C(x, y), z)$

# Przykładowe Ko-normy

- ▶ Ko-norma Zadeha:

$$C(x, y) = \max(x, y) \quad \forall x, y \in [0, 1]$$

- ▶ K-norma Mengara:

$$C(x, y) = x + y - xy \quad \forall x, y \in [0, 1]$$

- ▶ T-norma Łukasiewicza:

$$C(x, y) = \min(x + y, 1) \quad \forall x, y \in [0, 1]$$

# Negacja: zbiór rozmyty

- ▶ Negację zbioru  $\alpha$  definiujemy jako zbiór  $\neg\alpha$  o funkcji przynależności  $\mu_{\neg\alpha} : X \mapsto [0, 1]$  określonej wzorem  $\mu_{\neg\alpha}(x) = 1 - \mu_{\alpha}(x)$ .
- ▶ Dla  $\alpha$  równego  $\{(x_1, 0.4), (x_2, 0), (x_3, 0.5), (x_4, 1)\}$ ,  $\neg\alpha$  równa się:  $\{(x_1, 0.6), (x_2, 1), (x_3, 0.5), (x_4, 0)\}$



# Dualność: T-norm i ko-norm

- ▶  $\alpha \vee \beta = \neg(\neg\alpha \wedge \neg\beta)$
- ▶ Na przykład:  $(\min, \max, 1 - x)$
- ▶  $(T\text{-Łukasiewicz}, C\text{-Łukasiewicz}, 1-x)$

# Implikacja dla zbiorów rozmytych

- ▶ Jak w kontekście klasycznym, możemy zdefiniować:  
 $\alpha \Rightarrow \beta = \neg \alpha \vee \beta$ .
- ▶ Zadeh:  $\mu_{\alpha \Rightarrow \beta}(x) = \max(1 - \mu_{\alpha}(x), \mu_{\beta}(x))$
- ▶ Łukasiewicz:  $\mu_{\alpha \Rightarrow \beta}(x) = \min(1, 1 - \mu_{\alpha}(x) + \mu_{\beta}(x))$

Dziękuję za uwagę